

# 2024-1 인공지능론 과제 보고서

정보통계학과 빅데이터전공 신재호, 이현섭

1. 개요

2. 모델 설명

3. 데이터 설명 및 수집

4. 실험 결과

5. 결론

## 1. 개요

최근 국내 제조산업에서 스마트 팩토리 구축이 필요하며, 이는 4차 산업 혁명의 발전으로 인해 제조산업을 발전시킬 수 있는 방안으로 뽑히고 있다. 스마트 팩토리 시스템의 발전을 위해서 딥러닝을 기반으로 한 제품 불량 검사 시스템, AI를 기반으로 하여 제품의 결함을 찾아내는 프로그램 및 방안을 찾고 있다.

제조업에서는 제품의 품질관리가 매우 중요한 과제이다. 부품의 결함 및 오차가 많을수록 부품의 질이 떨어지고, 이는 곧 해당 기업의 수익과도 영향을 줄 것이다. 특히 제품관리의 부분에서 여러 시스템과 제도를 마련한 대기업과는 달리 중소기업은 대기업보다 불량률과 인건비 비율이 높아 경쟁에서 밀리는 상황이며, 생산품의 질보다는 값싼 제품을 생산하는데 집중하고 있다.

하지만, 중소기업의 경우에는 숙련된 작업자들이 주관적인 분석으로 제품의 불량을 수작업으로 판별하고 있지만 장시간의 동일한 업무로 인한 피로, 인간마다 다른 주관적인 판단으로 인해 검사의 신뢰도가 떨어질 수 있으며, 마지막으로 작업자 각각이 다른 경력과 숙련도를 가지고 있기 때문에 검사 속도 및 정확도에 대하여 떨어질 수 밖에 없을 것이다.

따라서 딥러닝 기술을 활용한 제품 불량 자동 검출 시스템의 구축은 기업들이 스마트 팩토리를 구현하기 위한 주요한 투자 대상 중 하나로 부각되며, 많은 기업이 이를 위해 지속해서 자금을 투자하고 있는 상황이다.

그러므로 높은 수준의 정확도를 여러 기업의 공장에서 보유할 수 있도록 방법을 고안한 연구를 진행하게 되었으며, 수많은 부품의 적합과 결함을 탐지하기 위한 실험을 진행하였다.

## 2. 모델 설명

이번 실험에서는 머신 비전에 적용하는 검출 기법 중 물체 인식에 탁월한 성능을 보이며, 계속해서 연구 및 발전을 이루고 있는 CNN 딥러닝 기법을 사용하려고 한다. 다양한 CNN 알고리즘을 활용하여 불량 탐지 성능을 비교하고 분석할 것이며, 사용하게 될 모델은 2개이며, ResNet과 efficientNet을 사용하려고 한다.


### ResNet

152개의 층을 가지고 있으며, 이전 모델인 GoogLeNet의 22개의 층보다 더욱 깊어진 특징이 있다. Residual Block을 제안하여 입력값을 출력값에 더해줄 수 있도록 지름길을 하나 만들어주며, 그림은 (1)과 같다. 초기에 모델을 설정할 때 Dropout은 없으


며 Batch Size는 256으로 규정하였다. 사용한 옵티마이저는 SGD+Momentum으로 0.9로 정하였고, LearningRate는 0.1로 설정하였다.

또한 차이만을 학습한다고 해서 ‘잔차학습’이라고 불리며, 변화량만 학습하는 CNN 알고리즘이다. 기존에는 각 layer에 ReLU 활성화 함수를 사용하여 통과하는 방식이었다면, 해당 모델에서는 기존 방식에서 identity 선을 만들어서 통과하는 방식이다. 그림 (2)의 모습과 같다.

이를 skip-connection이라고 하며,  $x$ 가 들어와서  $F(x)$ 가 나가는 것이 일반적이지만,  $x + F(x)$ 가 나가게끔 연결해 주는 것이다. 또한 VGGNET과는 다르게 층이 깊은 모습을 볼 수 있으며, 실제로 성능의 결과가 인간이 인식하는 성능보다 결과가 좋게 나왔음을 알 수 있다.



그림(1)






그림(2)

## EfficientNet

ResNet 이후 효율적인 모델 구축을 위해 depth, width, resolution을 스케일링하는 방법을 제안하였고, 이를 위하여 EfficientNet을 제안하게 됨.

CNN에 영향을 주는 다양한 변수가 존재하며, 대표적으로는 depth, width, resolution로 총 3가지의 변수를 들 수 있다. 그러나 이 3가지의 변수를 고려한 연구가 당시에는 없다는 점을 지적하며 depth, width, resolution을 어떻게 ‘체계적으로’ 증가시켜야 모델의 성능이 가장 ‘효율적으로’ 증가하는지에 대한 연구는 없었음. 따라서 이 부분에 초점을 맞춰 연구를 진행하게 됨.



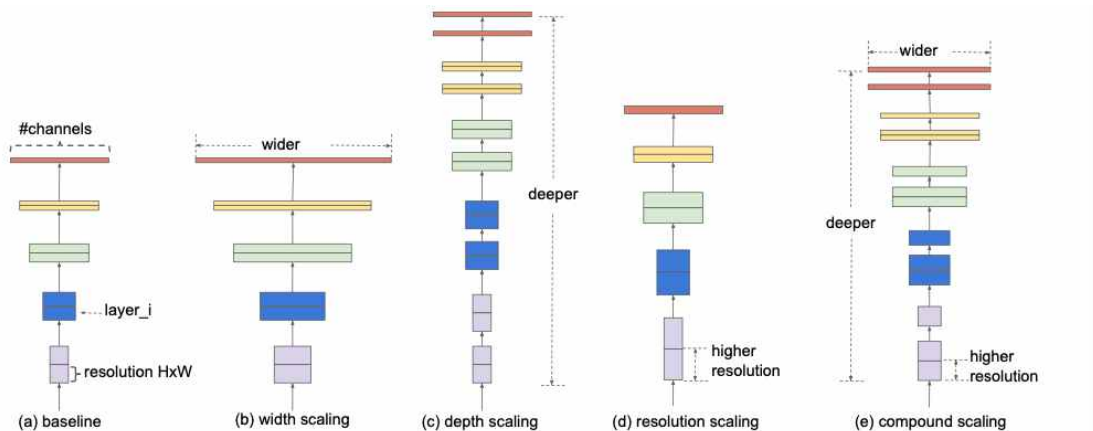


Figure 2. **Model Scaling.** (a) is a baseline network example; (b)-(d) are conventional scaling that only increases one dimension of network width, depth, or resolution. (e) is our proposed compound scaling method that uniformly scales all three dimensions with a fixed ratio.

그림(3) : EfficientNet의 Compound Scaling

우선 Baseline 모델을 만들어 딥러닝 방법을 사용할 때 목적 함수를 정해주고 Backpropagation을 통해 학습할 수 있도록 한다. 여기서는 Neural Architecture Search(NAS)방법을 사용함.

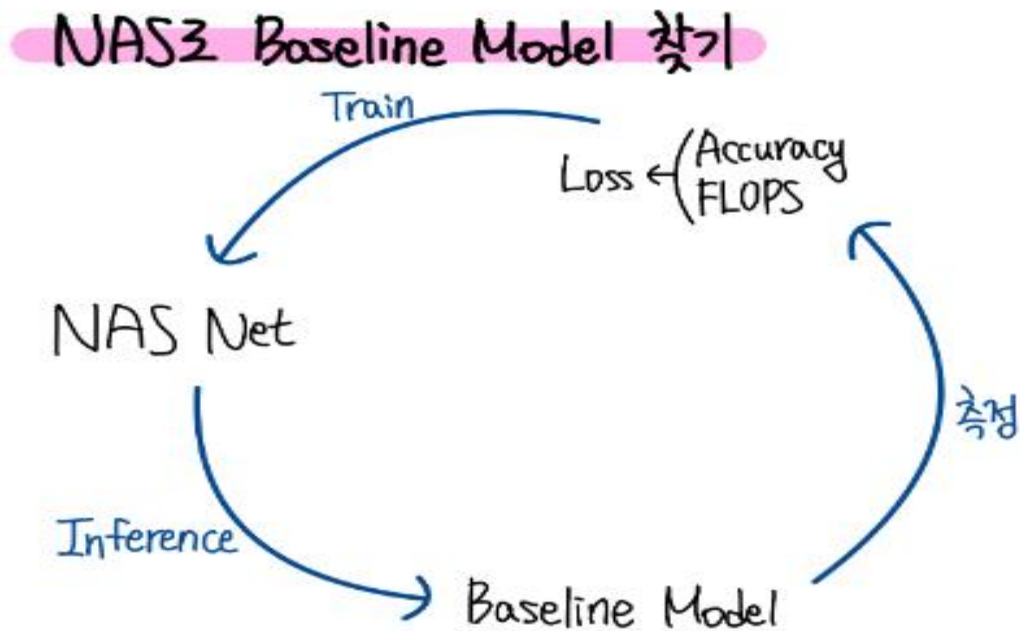


그림4 : NAS Baseline 모델

Compound Scale Up 방법을 적용하여 Depth,Width,Resolution을 찾는다. 해당 조합은 Small Grid Search 방법으로 찾으며, 결과는 그림 5와 같다.

### Grid Search로 $\alpha, \beta, \gamma$ 찾기

$\alpha$	$\beta$	$\gamma$	$\alpha \times \beta^2 \times \gamma^2$	Acc & FLOPS 종합 score
	:		$\frac{2}{2}$	:
	:		$\frac{2}{2}$	:
1.2	1.1	1.5	$\frac{2}{2}$	Max
	:		$\frac{2}{2}$	:
	:		$\frac{2}{2}$	:
	:		$\frac{2}{2}$	:

그림5 : Grid Search로 변수 찾기

다양한 변수 조합이 나올 것이고, 여기서 더 큰 모델을 만들고 싶으면 비율을 고정한 채로 Scale만 키워지면 될 것이다. 그림6은 EfficientNet의 각 모델을 보여준다.

### Scaling up EfficientNet

D	W	R	EfficientNet
1.2	1.1	1.5	$B_0$
$1.2^{n_1}$	$1.1^{n_1}$	$1.5^{n_1}$	$B_1$
$1.2^{n_2}$	$1.1^{n_2}$	$1.5^{n_2}$	$B_2$
:	:	:	:
$1.2^{n_b}$	$1.1^{n_b}$	$1.5^{n_b}$	$B_n$

$(n_1 < n_2 < n_3 \dots n_b)$

그림6 : 각 EfficientNet의 모델

## 3. 데이터 설명 및 수집




그림7 : 구리 필터 결함 데이터

본 연구의 연구 대상은 구리 필터 건조기로, 여러 냉동 장치에 사용이 된다. 또한 냉동 장치의 냉매의 순환 과정에서 오염물질을 걸러주어 파손을 막고 냉동 효율을 증가시킨다. 따라서 구리 필터 건조기는 정확하게 불량을 판단해야 하며, 이에 대한 결함 여부를 자동으로 분류하는 모형을 CNN 네트워크를 통해서 만들어볼 계획이다.

총 데이터 개수는 31,013개로 전체 데이터 중 불량데이터는 1,199개로 약 4%에 해당된다. 구리 필터 데이터는 Normal, Over-welding, Under-welding으로 총 3가지이다. 또한 불량데이터를 정확하게 예측하기 위해서 3가지의 조건을 적용하여 실험을 진행하고자 한다.

1. Pretraining 사용 유무
2. 전이 학습 사용 시 특정 레이어 고정 유무(requires\_grad 사용)
3. 데이터셋에서 확률을 조정하기 위해 사용되는 sampler 사용 유무

위와 같은 3가지 조건을 모두 조합하여 각 CNN 알고리즘 모델을 고려하였을 때 최적의 정확도 및 예측 성능을 보이는 값을 찾고자 한다. 정확도 점수는 f1\_score를 사용한다.

## 4. 실험 결과

Model	pretrained	required_grad	sampler	Train_loss	Valid_loss	Valid_accuracy	epoch1/min	epoch	f1_score
Resnet50	TRUE	TRUE	TRUE	0.005	0.107	98.40%	9~13	30	0.9807
			FALSE	0.005	0.113	98.10%	11~13	30	0.9803
		FALSE	TRUE	1.101	1.093	60.85%	10~12	30	0.7379
			FALSE	0.191	0.183	96.32%	8~12	30	0.9397
	FALSE	TRUE	TRUE	0.015	0.108	97.90%	9~13	30	0.9745
			FALSE	0.015	0.107	97.84%	10~13	30	0.9689
EfficientNetv2	TRUE	TRUE	TRUE	0.023	0.085	97.98%	16~18	30	0.9767
			FALSE	0.019	0.129	97.63%	16~18	30	0.9757
		FALSE	TRUE	4.029	5.446	48.56%	6~12	30	0.6139
			FALSE	0.666	0.639	92.66%	13~14	30	0.9225
	FALSE	TRUE	TRUE	0.022	0.208	97.63%	14~16	30	0.9707
			FALSE	0.017	0.147	97.71%	14~17	30	0.9721

표 1 CNN 모델 사용시 정확도 및 f1\_score 결과

실험 결과로 Resnet과 EfficientNet 모두 사전 학습 모형을 사용하며 모든 레이어를 학습하였을 때, f1\_score가 높게 나오며, valid\_accuracy도 높게 나옴을 확인할 수 있다.

전체성능을 비교하였을 때, EfficientNet의 결과는 97.63~97.98의 valid\_accuracy가 나왔지만, Resnet의 결과는 98.1~98.4의 valid\_accuracy가 나오며 Resnet을 사용하였을 때 성능이 더 좋음을 확인할 수 있었다.




사진 1 각 부분 인식 여부 확인 Grad-Cam  
(왼쪽부터 Normal, Over-welding, Under-welding)

높은 정확도를 가진 모델들을 학습시켜 Grad-Cam을 이용하여 구리 필터의 탐지를 확인하였다. 비교 결과 정상 데이터는 전체를 학습하였다는 것을 알 수 있고, 과적합된 경우는 아래를, 미용접된 경우는 미용접된 부분을 인식하였다는 것을 파악할 수 있다.

## 5. 결론

현재 사용되고 있는 구리 필터 데이터로 정상, 과용접, 미용접을 파악하는 탐지 연구를 진행하였다. 실험 결과 ResNet에서 가장 좋은 성능을 보였고, 해당 모델에서도 사전 모형을 학습시키고, 전체 레이어를 학습시켰을 때의 성능이 우수하다는 것을 연구를 통해서 확인할 수 있었다.

이에 대해 모델의 인식 여부를 Grad-Cam을 이용하여 학습한 결과, 각 불량품의 미용접, 과용접 부분을 인식하고 있다는 것을 파악하였다.

따라서 해당 연구를 통해 다른 제조 데이터의 과적합 및 불량 데이터를 더 정확하고 효율적으로 탐지할 수 있을 것이라는 기대감을 가지게 된다.